NOVA SCHOOL OF
SCIENCE & TECHNOLOGY
DEPARTMENT OF MATHEMATICS

Estatística Econométrica e Financeira

Trabalho

Guilherme Botelho nº70067

2º Semestre
Junho 2025

Conteúdo

1 Pergunta 1 **2**
1.1 Alínea (a) 2
1.1.1 Dedução da Função de Verosimilhança 2
1.1.2 Dedução da Função Log-Verosimilhança 3
1.1.3 Obtenção dos Estimadores de Máxima Verosimilhança 4
1.2 Alínea (b) 7
1.2.1 Dedução das funções estimadoras de mínimos quadrados 7
1.3 Alínea (c) 10
1.3.1 Dedução das funções estimadoras de martingalas lineares 10
1.4 Alínea (d) 11
1.4.1 Dedução da função de contraste baseada no esquema de Euler 11

2 Pergunta 2 **16**
2.1 Alínea (a) 16
2.2 Alínea (b) 17
2.3 Alínea (c) 19

Lista de Figuras

1 Código relizado da alínea a) 16
2 Gráfico gerado para a alínea (b). 17
3 Código utilizado para gerar o gráfico da alínea (b). 18
4 Código - parte 1: estimadores para a alínea (c). 19
5 Código - parte 2: estimadores para a alínea (c). 20
6 Código - parte 3: estimadores para a alínea (c). 20
7 Resultados da estimação dos parâmetros para a alínea (c). . . . 21

1 Pergunta 1

Considere o processo de Ornstein-Uhlenbeck definido pela seguinte equação diferencial estocástica (EDE):

$$dX_t = \alpha(\beta - X_t)\,dt + \sigma\,dW_t, \quad X_0 = x_0 \tag{1}$$

onde α , β e $\sigma > 0$ são constantes, e (W_t) é um processo Browniano.

Sejam $X_0, X_1, \ldots, X_n$ observações do processo $(X_t)_{t\geq 0}$ nos instantes $t_0 < t_1 < \ldots < t_n$ com $t_{i+1} - t_1 = \Delta$.

1.1 Alínea (a)

1.1.1 Dedução da Função de Verosimilhança

A função de verosimilhança para este processo de difusão é baseada na densidade de transição condicional $p(\Delta, X_i, X_{i+1}; \theta)$.

Para determinar $p(\Delta, X_i, X_{i+1}; \alpha, \beta, \sigma)$ iremos considerar a solução do processo Ornstein-Uhlenbeck:

$$X_t = x_0 e^{-\alpha t} + \beta(1 - e^{-\alpha t}) + \sigma \int_0^t e^{-\alpha(t-s)} dW_s.$$

Para o intervalo de t_i a t_{i+1} com $\Delta = t_{i+1} - t_i$, o valor esperado condicional é:

$$E[X_{t_{i+1}}|X_{t_i}] = X_{t_i} e^{-\alpha\Delta} + \beta(1 - e^{-\alpha\Delta}),$$

e a variância do termo estocástico $\sigma \int_{t_i}^{t_{i+1}} e^{-\alpha(t_{i+1}-s)} dW_s$ é calculada como:

$$\text{Var} = \sigma^2 \int_{t_i}^{t_{i+1}} e^{-2\alpha(t_{i+1}-s)} ds.$$

Resolvendo a integral:

$$\begin{aligned}\int_{t_i}^{t_{i+1}} e^{-2\alpha(t_{i+1}-s)}\,ds &= \int_0^{\Delta} e^{-2\alpha(\Delta-u)}\,du = e^{-2\alpha\Delta} \int_0^{\Delta} e^{2\alpha u}\,du \\ &= e^{-2\alpha\Delta}\left[\frac{e^{2\alpha u}}{2\alpha}\right]_0^{\Delta} = \frac{e^{-2\alpha\Delta}(e^{2\alpha\Delta} - 1)}{2\alpha} = \frac{1 - e^{-2\alpha\Delta}}{2\alpha}\end{aligned} \tag{2}$$

Portanto, a variância é:

$$\text{Var}(X_{t_{i+1}}|X_{t_i}) = \sigma^2 \cdot \frac{1 - e^{-2\alpha\Delta}}{2\alpha}.$$

Assim, $X_{t_{i+1}}|X_{t_i} \sim N\left(X_{t_i} e^{-\alpha\Delta} + \beta(1 - e^{-\alpha\Delta}), \frac{\sigma^2}{2\alpha}(1 - e^{-2\alpha\Delta})\right)$, e a densidade de transição é:

$$p(\Delta, X_i, X_{i+1}; \alpha, \beta, \sigma) = \frac{1}{\sqrt{2\pi \cdot \frac{\sigma^2}{2\alpha}(1 - e^{-2\alpha\Delta})}} \exp\left[-\frac{(X_{i+1} - X_i e^{-\alpha\Delta} - \beta(1 - e^{-\alpha\Delta}))^2}{2 \cdot \frac{\sigma^2}{2\alpha}(1 - e^{-2\alpha\Delta})}\right].$$

Substituindo na função de verosimilhança:

$$L_n(\alpha, \beta, \sigma) = \prod_{i=0}^{n-1} \frac{1}{\sqrt{2\pi \cdot \frac{\sigma^2}{2\alpha}(1 - e^{-2\alpha\Delta})}} \exp\left[-\frac{(X_{i+1} - X_i e^{-\alpha\Delta} - \beta(1 - e^{-\alpha\Delta}))^2}{2 \cdot \frac{\sigma^2}{2\alpha}(1 - e^{-2\alpha\Delta})}\right].$$

1.1.2 Dedução da Função Log-Verosimilhança

Tomamos o logaritmo natural da função de verosimilhança:

$$\log L_n(\alpha,\beta,\sigma) = \sum_{i=0}^{n-1} \log\left(\frac{1}{\sqrt{2\pi\cdot\frac{\sigma^2}{2\alpha}(1-e^{-2\alpha\Delta})}}\exp\left[-\frac{(X_{i+1}-X_ie^{-\alpha\Delta}-\beta(1-e^{-\alpha\Delta}))^2}{2\cdot\frac{\sigma^2}{2\alpha}(1-e^{-2\alpha\Delta})}\right]\right).$$

Aplicamos a propriedade do logaritmo para cada termo:

$$\log L_n(\alpha,\beta,\sigma) = \sum_{i=0}^{n-1}\left(\log\left(\frac{1}{\sqrt{2\pi\cdot\frac{\sigma^2}{2\alpha}(1-e^{-2\alpha\Delta})}}\right)+\log\left(\exp\left[-\frac{(X_{i+1}-X_ie^{-\alpha\Delta}-\beta(1-e^{-\alpha\Delta}))^2}{2\cdot\frac{\sigma^2}{2\alpha}(1-e^{-2\alpha\Delta})}\right]\right)\right).$$

- Primeiro termo: $\log\left(\frac{1}{\sqrt{x}}\right) = -\frac{1}{2}\log x$:

$$\log\left(\frac{1}{\sqrt{2\pi\cdot\frac{\sigma^2}{2\alpha}(1-e^{-2\alpha\Delta})}}\right) = -\frac{1}{2}\log\left(2\pi\cdot\frac{\sigma^2}{2\alpha}(1-e^{-2\alpha\Delta})\right).$$

- Segundo termo: $\log(\exp y) = y$:

$$\log\left(\exp\left[-\frac{(X_{i+1}-X_ie^{-\alpha\Delta}-\beta(1-e^{-\alpha\Delta}))^2}{2\cdot\frac{\sigma^2}{2\alpha}(1-e^{-2\alpha\Delta})}\right]\right) = -\frac{(X_{i+1}-X_ie^{-\alpha\Delta}-\beta(1-e^{-\alpha\Delta}))^2}{2\cdot\frac{\sigma^2}{2\alpha}(1-e^{-2\alpha\Delta})}.$$

Combinando:

$$\log L_n(\alpha,\beta,\sigma) = \sum_{i=0}^{n-1}\left[-\frac{1}{2}\log\left(2\pi\cdot\frac{\sigma^2}{2\alpha}(1-e^{-2\alpha\Delta})\right)-\frac{(X_{i+1}-X_ie^{-\alpha\Delta}-\beta(1-e^{-\alpha\Delta}))^2}{2\cdot\frac{\sigma^2}{2\alpha}(1-e^{-2\alpha\Delta})}\right].$$

Fatorizando os termos constantes:

$$\sum_{i=0}^{n-1}\left(-\frac{1}{2}\log\left(2\pi\cdot\frac{\sigma^2}{2\alpha}(1-e^{-2\alpha\Delta})\right)\right) = -\frac{n}{2}\log\left(2\pi\cdot\frac{\sigma^2}{2\alpha}(1-e^{-2\alpha\Delta})\right),$$

$$\log L_n(\alpha,\beta,\sigma) = -\frac{n}{2}\log\left(2\pi\cdot\frac{\sigma^2}{2\alpha}(1-e^{-2\alpha\Delta})\right)-\sum_{i=0}^{n-1}\frac{(X_{i+1}-X_ie^{-\alpha\Delta}-\beta(1-e^{-\alpha\Delta}))^2}{2\cdot\frac{\sigma^2}{2\alpha}(1-e^{-2\alpha\Delta})}.$$

Expandindo o primeiro termo:

$$\log\left(2\pi\cdot\frac{\sigma^2}{2\alpha}(1-e^{-2\alpha\Delta})\right) = \log(2\pi)+\log\left(\frac{\sigma^2}{2\alpha}(1-e^{-2\alpha\Delta})\right),$$

$$-\frac{n}{2}\log\left(2\pi\cdot\frac{\sigma^2}{2\alpha}(1-e^{-2\alpha\Delta})\right) = -\frac{n}{2}\log(2\pi)-\frac{n}{2}\log\left(\frac{\sigma^2}{2\alpha}(1-e^{-2\alpha\Delta})\right).$$

Forma final:

$$\log L_n(\alpha,\beta,\sigma) = -\frac{n}{2}\log(2\pi)-\frac{n}{2}\log\left(\frac{\sigma^2}{2\alpha}(1-e^{-2\alpha\Delta})\right)-\sum_{i=0}^{n-1}\frac{(X_{i+1}-X_ie^{-\alpha\Delta}-\beta(1-e^{-\alpha\Delta}))^2}{2\cdot\frac{\sigma^2}{2\alpha}(1-e^{-2\alpha\Delta})}.$$

1.1.3 Obtenção dos Estimadores de Máxima Verosimilhança

Para encontrar os estimadores de máxima verosimilhança ($\hat{\alpha}$, $\hat{\beta}$, $\hat{\sigma}$), derivamos a função log-verosimilhança em relação a cada parâmetro e igualamos a zero.

Estimador de β

Derivamos $\log L_n$ em relação a β:

$$\frac{\partial \log L_n}{\partial \beta} = \sum_{i=0}^{n-1} \frac{\partial}{\partial \beta}\left[-\frac{(X_{i+1} - X_i e^{-\alpha\Delta} - \beta(1-e^{-\alpha\Delta}))^2}{2 \cdot \frac{\sigma^2}{2\alpha}(1-e^{-2\alpha\Delta})}\right].$$

A derivada do termo dentro da soma é:

$$\frac{\partial}{\partial \beta}\left[-(X_{i+1} - X_i e^{-\alpha\Delta} - \beta(1-e^{-\alpha\Delta}))^2\right] = -2(X_{i+1} - X_i e^{-\alpha\Delta} - \beta(1-e^{-\alpha\Delta})) \cdot (-(1-e^{-\alpha\Delta})),$$

$$\frac{\partial \log L_n}{\partial \beta} = \sum_{i=0}^{n-1} \frac{(X_{i+1} - X_i e^{-\alpha\Delta} - \beta(1-e^{-\alpha\Delta}))(1-e^{-\alpha\Delta})}{\frac{\sigma^2}{2\alpha}(1-e^{-2\alpha\Delta})}.$$

Igualando a zero:

$$\sum_{i=0}^{n-1} \frac{(X_{i+1} - X_i e^{-\alpha\Delta} - \beta(1-e^{-\alpha\Delta}))(1-e^{-\alpha\Delta})}{\frac{\sigma^2}{2\alpha}(1-e^{-2\alpha\Delta})} = 0,$$

$$\sum_{i=0}^{n-1}(X_{i+1} - X_i e^{-\alpha\Delta} - \beta(1-e^{-\alpha\Delta})) = 0,$$

$$\sum_{i=0}^{n-1} X_{i+1} - \sum_{i=0}^{n-1} X_i e^{-\alpha\Delta} - \beta n(1-e^{-\alpha\Delta}) = 0,$$

$$-\beta n(1-e^{-\alpha\Delta}) = \sum_{i=0}^{n-1} X_{i+1} - \sum_{i=0}^{n-1} X_i e^{-\alpha\Delta},$$

$$\hat{\beta} = \frac{\sum_{i=0}^{n-1}(X_{i+1} - X_i e^{-\alpha\Delta})}{n(1-e^{-\alpha\Delta})}.$$

Estimador de σ

Derivamos $\log L_n$ em relação a σ:

$$\frac{\partial \log L_n}{\partial \sigma} = \frac{\partial}{\partial \sigma}\left[-\frac{n}{2}\log\left(\frac{\sigma^2}{2\alpha}(1-e^{-2\alpha\Delta})\right)\right] + \sum_{i=0}^{n-1} \frac{\partial}{\partial \sigma}\left[-\frac{(X_{i+1} - X_i e^{-\alpha\Delta} - \beta(1-e^{-\alpha\Delta}))^2}{2 \cdot \frac{\sigma^2}{2\alpha}(1-e^{-2\alpha\Delta})}\right].$$

- Primeiro termo: $\frac{\partial}{\partial \sigma}\left(-\frac{n}{2}\log\left(\frac{\sigma^2}{2\alpha}(1-e^{-2\alpha\Delta})\right)\right)$.

$$-\frac{n}{2}\log\left(\frac{\sigma^2}{2\alpha}(1-e^{-2\alpha\Delta})\right) = -\frac{n}{2}\log(\sigma^2) - \frac{n}{2}\log\left(\frac{1}{2\alpha}(1-e^{-2\alpha\Delta})\right),$$

Logo,

$$\frac{\partial}{\partial\sigma}\left(-\frac{n}{2}\log(\sigma^2)\right) = -\frac{n}{2}\cdot 2\cdot\frac{1}{\sigma} = -\frac{n}{\sigma}.$$

- Segundo termo: $\frac{\partial}{\partial\sigma}\left(-\sum_{i=0}^{n-1}\frac{(X_{i+1}-X_ie^{-\alpha\Delta}-\beta(1-e^{-\alpha\Delta}))^2}{2\cdot\frac{\sigma^2}{2\alpha}(1-e^{-2\alpha\Delta})}\right)$.

$$\frac{\partial}{\partial\sigma}\left(-\frac{(X_{i+1}-X_ie^{-\alpha\Delta}-\beta(1-e^{-\alpha\Delta}))^2}{2\cdot\frac{\sigma^2}{2\alpha}(1-e^{-2\alpha\Delta})}\right) = -(X_{i+1}-X_ie^{-\alpha\Delta}-\beta(1-e^{-\alpha\Delta}))^2\cdot\frac{\partial}{\partial\sigma}\left(\frac{1}{2\cdot\frac{\sigma^2}{2\alpha}(1-e^{-2\alpha\Delta})}\right),$$

$$\frac{\partial}{\partial\sigma}\left(\frac{\alpha}{\sigma^2(1-e^{-2\alpha\Delta})}\right) = \frac{\alpha}{1-e^{-2\alpha\Delta}}\frac{\partial}{\partial\sigma}\left(\frac{1}{\sigma^2}\right) = \frac{\alpha}{1-e^{-2\alpha\Delta}}\left(-\frac{2}{\sigma^3}\right) = -\frac{2\alpha}{\sigma^3(1-e^{-2\alpha\Delta})},$$

$$\frac{\partial}{\partial\sigma}\left(-\frac{(X_{i+1}-X_ie^{-\alpha\Delta}-\beta(1-e^{-\alpha\Delta}))^2}{2\cdot\frac{\sigma^2}{2\alpha}(1-e^{-2\alpha\Delta})}\right) = \frac{2\alpha(X_{i+1}-X_ie^{-\alpha\Delta}-\beta(1-e^{-\alpha\Delta}))^2}{\sigma^3(1-\exp^{-2\alpha\Delta})},$$

$$-\sum_{i=0}^{n-1}\frac{2\alpha(X_{i+1}-X_ie^{-\alpha\Delta}-\beta(1-e^{-\alpha\Delta}))^2}{\sigma^3(1-e^{-2\alpha\Delta})}.$$

Derivada total:

$$\frac{\partial\log L_n}{\partial\sigma} = -\frac{n}{\sigma}+\sum_{i=0}^{n-1}\frac{2\alpha(X_{i+1}-X_ie^{-\alpha\Delta}-\beta(1-e^{-\alpha\Delta}))^2}{\sigma^3(1-e^{-2\alpha\Delta})}.$$

Igualando a zero:

$$-\frac{n}{\sigma}+\sum_{i=0}^{n-1}\frac{2\alpha(X_{i+1}-X_ie^{-\alpha\Delta}-\beta(1-e^{-\alpha\Delta}))^2}{\sigma^3(1-e^{-2\alpha\Delta})} = 0,$$

$$\frac{n}{\sigma} = \sum_{i=0}^{n-1}\frac{2\alpha(X_{i+1}-X_ie^{-\alpha\Delta}-\beta(1-e^{-\alpha\Delta}))^2}{\sigma^3(1-e^{-2\alpha\Delta})},$$

$$n\sigma^2 = \frac{2\alpha}{1-e^{-2\alpha\Delta}}\sum_{i=0}^{n-1}(X_{i+1}-X_ie^{-\alpha\Delta}-\beta(1-e^{-\alpha\Delta}))^2,$$

$$\sigma^2 = \frac{1}{n}\frac{2\alpha}{1-e^{-2\alpha\Delta}}\sum_{i=0}^{n-1}(X_{i+1}-X_ie^{-\alpha\Delta}-\beta(1-e^{-\alpha\Delta}))^2,$$

É possível observar que $\frac{2\alpha}{1-e^{-2\alpha\Delta}}$ é o inverso da variância condicional $\frac{\sigma^2}{2\alpha}(1-e^{-2\alpha\Delta})$. Vamos então ajustar:

$$\frac{1}{\frac{\sigma^2}{2\alpha}(1-e^{-2\alpha\Delta})} = \frac{2\alpha}{\sigma^2(1-e^{-2\alpha\Delta})}$$

Logo,

$$-\frac{n}{\sigma}+\frac{1}{\sigma^3}\sum_{i=0}^{n-1}(X_{i+1}-X_ie^{-\alpha\Delta}-\beta(1-e^{-\alpha\Delta}))^2 = 0,$$

$$\hat{\sigma}^2 = \frac{1}{n}\sum_{i=0}^{n-1}(X_{i+1}-X_ie^{-\alpha\Delta}-\beta(1-e^{-\alpha\Delta}))^2.$$

Estimador de α

Derivamos $\log L_n$ em relação a α:

$$\frac{\partial \log L_n}{\partial \alpha} = -\frac{n}{2}\log(2\pi) + \frac{\partial}{\partial \alpha}\left(-\frac{n}{2}\log\left(\frac{\sigma^2}{2\alpha}(1-e^{-2\alpha\Delta})\right)\right) + \frac{\partial}{\partial \alpha}\left(-\sum_{i=0}^{n-1}\frac{(X_{i+1}-X_i e^{-\alpha\Delta} - \beta(1-e^{-\alpha\Delta}))^2}{2\cdot\frac{\sigma^2}{2\alpha}(1-e^{-2\alpha\Delta})}\right).$$

- Primeiro termo: $\frac{\partial}{\partial\alpha}\left(-\frac{n}{2}\log\left(\frac{\sigma^2}{2\alpha}(1-e^{-2\alpha\Delta})\right)\right)$.

$$-\frac{n}{2}\log\left(\frac{\sigma^2}{2\alpha}(1-e^{-2\alpha\Delta})\right) = -\frac{n}{2}\log(\sigma^2) - \frac{n}{2}\log\left(\frac{1}{2\alpha}\right) - \frac{n}{2}\log(1-e^{-2\alpha\Delta}).$$

Sabemos que o primeiro termo não depende de α, logo iremos seguir para o segundo termo:

$$\frac{\partial}{\partial\alpha}\left(-\frac{n}{2}\log\left(\frac{1}{2\alpha}\right)\right) = -\frac{n}{2}\left(-\frac{1}{\alpha}\right) = \frac{n}{2\alpha},$$

$$\frac{\partial}{\partial\alpha}\left(\log(1-e^{-2\alpha\Delta})\right) = \frac{1}{1-e^{-2\alpha\Delta}}\frac{\partial}{\partial\alpha}(1-e^{-2\alpha\Delta}),$$

$$\frac{\partial}{\partial\alpha}\left(1-e^{-2\alpha\Delta}\right) = 2\Delta e^{-2\alpha\Delta},$$

Logo,

$$\frac{\partial}{\partial\alpha}\left(\log(1-e^{-2\alpha\Delta})\right) = \frac{2\Delta e^{-2\alpha\Delta}}{1-e^{-2\alpha\Delta}}.$$

A derivada toda do segundo termo corresponde:

$$\frac{\partial}{\partial\alpha}\left(-\frac{n}{2}\log(1-e^{-2\alpha\Delta})\right) = -\frac{n}{2}\cdot\frac{2\Delta e^{-2\alpha\Delta}}{1-e^{-2\alpha\Delta}} = -\frac{n\Delta e^{-2\alpha\Delta}}{1-e^{-2\alpha\Delta}},$$

$$\frac{\partial}{\partial\alpha}\left(-\frac{n}{2}\log\left(\frac{\sigma^2}{2\alpha}(1-e^{-2\alpha\Delta})\right)\right) = \frac{n}{2\alpha} - \frac{n\Delta e^{-2\alpha\Delta}}{1-e^{-2\alpha\Delta}}.$$

- Terceiro termo: $\frac{\partial}{\partial\alpha}\left(-\sum_{i=0}^{n-1}\frac{(X_{i+1}-X_i e^{-\alpha\Delta}-\beta(1-e^{-\alpha\Delta}))^2}{2\cdot\frac{\sigma^2}{2\alpha}(1-e^{-2\alpha\Delta})}\right)$.

Definimos $u_i = X_{i+1} - X_i e^{-\alpha\Delta} - \beta(1-e^{-\alpha\Delta})$, $d = 2\cdot\frac{\sigma^2}{2\alpha}(1-e^{-2\alpha\Delta})$:

$$\frac{\partial u_i}{\partial\alpha} = (X_i+\beta)\Delta e^{-\alpha\Delta},$$

$$\frac{\partial(u_i^2)}{\partial\alpha} = 2u_i(X_i+\beta)\Delta e^{-\alpha\Delta},$$

$$\frac{\partial}{\partial\alpha}\left(\frac{\alpha}{\sigma^2(1-e^{-2\alpha\Delta})}\right) = \frac{2\alpha\Delta e^{-2\alpha\Delta}(\alpha+1)}{\sigma^2(1-e^{-2\alpha\Delta})^2},$$

$$\frac{\partial}{\partial\alpha}\left(-\frac{u_i^2}{d}\right) = -\frac{\alpha}{\sigma^2(1-e^{-2\alpha\Delta})}\cdot 2u_i(X_i+\beta)\Delta e^{-\alpha\Delta} - u_i^2\cdot\frac{2\alpha\Delta e^{-2\alpha\Delta}(\alpha+1)}{\sigma^2(1-e^{-2\alpha\Delta})^2},$$

$$-\sum_{i=0}^{n-1}\left[\frac{2\alpha u_i(X_i+\beta)\Delta e^{-\alpha\Delta}}{\sigma^2(1-e^{-2\alpha\Delta})} + u_i^2\cdot\frac{2\alpha\Delta e^{-2\alpha\Delta}(\alpha+1)}{\sigma^2(1-e^{-2\alpha\Delta})^2}\right].$$

Derivada total:

$$\frac{\partial \log L_n}{\partial \alpha} = \frac{n}{2\alpha} - \frac{n\Delta e^{-2\alpha\Delta}}{1-e^{-2\alpha\Delta}} - \sum_{i=0}^{n-1}\left[\frac{2\alpha u_i(X_i+\beta)\Delta e^{-\alpha\Delta}}{\sigma^2(1-e^{-2\alpha\Delta})} + u_i^2 \cdot \frac{2\alpha\Delta e^{-2\alpha\Delta}(\alpha+1)}{\sigma^2(1-e^{-2\alpha\Delta})^2}\right].$$

Igualar esta expressão a zero para encontrar $\hat{\alpha}$ vai resultar numa equação não linear complexa devido aos termos $e^{-\alpha\Delta}$ e $e^{-2\alpha\Delta}$. Para obter o estimador $\hat{\alpha}$, utilizamos o método de Newton-Raphson, resolvendo $\frac{\partial \log L_n}{\partial \alpha} = 0$ iterativamente:

$$\frac{\partial \log L_n}{\partial \alpha} = \frac{n}{2\alpha} - \frac{n\Delta e^{-2\alpha\Delta}}{1-e^{-2\alpha\Delta}} - \sum_{i=0}^{n-1}\left[\frac{2\alpha u_i(X_i+\beta)\Delta e^{-\alpha\Delta}}{\sigma^2(1-e^{-2\alpha\Delta})} + \frac{u_i^2(1-e^{-2\alpha\Delta}+2\alpha\Delta e^{-2\alpha\Delta})}{\sigma^2(1-e^{-2\alpha\Delta})^2}\right],$$

onde $u_i = X_{i+1} - X_i e^{-\alpha\Delta} - \beta(1-e^{-\alpha\Delta})$.

A iteração é dada por:

$$\alpha_{k+1} = \alpha_k - \frac{\left.\frac{\partial \log L_n}{\partial \alpha}\right|_{\alpha=\alpha_k}}{\left.\frac{\partial^2 \log L_n}{\partial \alpha^2}\right|_{\alpha=\alpha_k}}.$$

-Primeiro termo: $\frac{n}{2\alpha} - \frac{n\Delta e^{-2\alpha\Delta}}{1-e^{-2\alpha\Delta}}$.

- $\frac{\partial}{\partial\alpha}\left(\frac{n}{2\alpha}\right) = -\frac{n}{2\alpha^2}$

- $\frac{\partial}{\partial\alpha}\left(-\frac{n\Delta e^{-2\alpha\Delta}}{1-e^{-2\alpha\Delta}}\right) = \frac{(2n\Delta^2 e^{-2\alpha\Delta})(1-e^{-2\alpha\Delta})-(-n\Delta e^{-2\alpha\Delta})(2\Delta e^{-2\alpha\Delta})}{(1-e^{-2\alpha\Delta})^2}$,

$$= \frac{4n\Delta^2 e^{-2\alpha\Delta} - 2n\Delta^2 e^{-4\alpha\Delta}}{(1-e^{-2\alpha\Delta})^2}.$$

- Segundo termo : Devido à complexidade, a segunda derivada é aproximada numericamente ou requer derivação simbólica detalhada.

A iteração fica:

$$\alpha_{k+1} = \alpha_k - \frac{\frac{n}{2\alpha_k} - \frac{n\Delta e^{-2\alpha_k\Delta}}{1-e^{-2\alpha_k\Delta}} - \sum_{i=0}^{n-1}\left[\frac{2\alpha_k u_i(X_i+\beta)\Delta e^{-\alpha_k\Delta}}{\sigma^2(1-e^{-2\alpha_k\Delta})} + \frac{u_i^2(1-e^{-2\alpha_k\Delta}+2\alpha_k\Delta e^{-2\alpha_k\Delta})}{\sigma^2(1-e^{-2\alpha_k\Delta})^2}\right]}{\left.\frac{\partial^2 \log L_n}{\partial \alpha^2}\right|_{\alpha=\alpha_k}}.$$

O procedimento vai consistir em escolher um $alpha_0$, calcular um u_1 com o $\hat{\beta}$ e $\hat{\sigma}$. Avaliamos o $\frac{\partial \log L_n}{\partial \alpha}$ e aproximamos o $\frac{\partial^2 \log L_n}{\partial \alpha^2}$. Iremos repetir isto até obtermos $|\alpha_{k+1} - \alpha_k| < 10^{-6}$. O resultado obtido, $\hat{\alpha}$ vai ser um valor convergente.

1.2 Alínea (b)

1.2.1 Dedução das funções estimadoras de mínimos quadrados

Para o método dos mínimos quadrados é minimizada a soma dos quadrados dos erros entre os valores observados e os valores esperados do processo.

Vamos então calcular a função para os minimos quadrados.

Nós sabemos da alínea anterior que:

$$X_{i+1} = X_i e^{-\alpha\Delta} + \beta(1 - e^{-\alpha\Delta}) + \sigma \int_{t_i}^{t+1} e^{-\alpha(t_{i+1}-s)} dW_s.$$

Onde $\Delta = t_{i+1} - t_i$ e o último termo é uma integral estocástica que representa a contribuição do ruído browniano dW_t ao longo do intervalo $[t_i, t_{i+1}]$.

Iremos representar o último termo como ϵ_i, onde este corresponde a um ero gaussiano com média zero e variância $\frac{\sigma^2(1-e^{-2\alpha\Delta})}{2\alpha}$.
Logo,

$$X_{i+1} = X_i e^{-\alpha\Delta} + \beta(1 - e^{-\alpha\Delta}) + \epsilon_i$$

O valor esperado condicional é:

$$E[X_{t_{i+1}}|X_{t_i}] = X_{t_i} e^{-\alpha\Delta} + \beta(1 - e^{-\alpha\Delta})$$

A função estimadora de mínimos quadrados é definida como a soma dos quadrados dos resíduos, logo:

$$MQ_n(\alpha, \beta) = \sum_{i=0}^{n-1} \left[X_{i+1} - (X_i e^{-\alpha\Delta} + \beta(1 - e^{-\alpha\Delta}))\right]^2.$$

Estimador de β

$$\frac{\partial MQ_n}{\partial \beta} = \frac{\partial}{\partial \beta} \sum_{i=0}^{n-1} \left[X_{i+1} - (X_i e^{-\alpha\Delta} + \beta(1 - e^{-\alpha\Delta}))\right]^2,$$

$$\frac{\partial MQ_n}{\partial \beta} = 2 \sum_{i=0}^{n-1} \left[X_{i+1} - X_i e^{-\alpha\Delta} - \beta(1 - e^{-\alpha\Delta})\right] \cdot \frac{\partial}{\partial \beta} \left[-\beta(1 - e^{-\alpha\Delta})\right],$$

$$\frac{\partial MQ_n}{\partial \beta} = 2 \sum_{i=0}^{n-1} \left[X_{i+1} - X_i e^{-\alpha\Delta} - \beta(1 - e^{-\alpha\Delta})\right] \cdot (-(1 - e^{-\alpha\Delta})).$$

Igualamos a zero e isolamos β:

$$\sum_{i=0}^{n-1} \left[X_{i+1} - X_i e^{-\alpha\Delta} - \beta(1 - e^{-\alpha\Delta})\right](1 - e^{-\alpha\Delta}) = 0,$$

$$\hat{\beta} = \frac{\sum_{i=0}^{n-1}(X_{i+1} - X_i e^{-\alpha\Delta})}{n(1 - e^{-\alpha\Delta})}.$$

Pois $(1 - e^{-\alpha\Delta})$ é constante em relação a i.

Estimador de α

$$\frac{\partial MQ_n}{\partial \alpha} = \frac{\partial}{\partial \alpha} \sum_{i=0}^{n-1} \left[X_{i+1} - (X_i e^{-\alpha\Delta} + \beta(1 - e^{-\alpha\Delta}))\right]^2,$$

$$\frac{\partial MQ_n}{\partial \alpha} = 2 \sum_{i=0}^{n-1} \left[X_{i+1} - X_i e^{-\alpha\Delta} - \beta(1 - e^{-\alpha\Delta})\right] \cdot \frac{\partial}{\partial \alpha} \left[-X_i e^{-\alpha\Delta} - \beta(1 - e^{-\alpha\Delta})\right].$$

Vamos fazer as derivadas internas:

- $\dfrac{\partial}{\partial\alpha}\left(-X_i e^{-\alpha\Delta}\right) = X_i\Delta e^{-\alpha\Delta}$
- $\dfrac{\partial}{\partial\alpha}\left(-\beta(1-e^{-\alpha\Delta})\right) = \beta\Delta e^{-\alpha\Delta}$
- Total: $(X_i+\beta)\Delta e^{-\alpha\Delta}$

Substituindo β por $\hat{\beta}$,
$\frac{\partial}{\partial\alpha}\left[-X_i e^{-\alpha\Delta} - \hat{\beta}(1-e^{-\alpha\Delta})\right] = (X_i+\hat{\beta})\Delta e^{-\alpha\Delta}$.

Portanto,

$$\frac{\partial MQ_n}{\partial\alpha} = 2\sum_{i=0}^{n-1}\left[X_{i+1} - X_i e^{-\alpha\Delta} - \frac{\sum_{j=0}^{n-1}(X_{j+1} - X_j e^{-\alpha\Delta})}{n(1-e^{-\alpha\Delta})}(1-e^{-\alpha\Delta})\right]\cdot(X_i+\hat{\beta})\Delta e^{-\alpha\Delta}.$$

Igualando a zero,

$$\sum_{i=0}^{n-1}\left[X_{i+1} - X_i e^{-\alpha\Delta} - \frac{\sum_{j=0}^{n-1}(X_{j+1} - X_j e^{-\alpha\Delta})}{n}\right](X_i+\hat{\beta})\Delta e^{-\alpha\Delta} = 0.$$

A equação é não linear em α devido aos termos exponenciais $e^{-\alpha\Delta}$ e à dependência de $\hat{\beta}$ em α. Não existinto uma solução analítica fechada. Iremos então usar o método de Newton-Raphson. A iteração é:

$$\alpha_{k+1} = \alpha_k - \frac{\left.\frac{\partial MQ_n}{\partial\alpha}\right|_{\alpha=\alpha_k}}{\left.\frac{\partial^2 MQ_n}{\partial\alpha^2}\right|_{\alpha=\alpha_k}}.$$

Iremos então realizar a segunda derivada, $(\frac{\partial^2 MQ_n}{\partial\alpha^2})$,
Derivamos $\frac{\partial MQ_n}{\partial\alpha}$ em relação a α. Considerando o termo principal:

$$\frac{\partial}{\partial\alpha}\left[\left(X_{i+1} - X_i e^{-\alpha\Delta} - \hat{\beta}(1-e^{-\alpha\Delta})\right)(X_i+\hat{\beta})\Delta e^{-\alpha\Delta}\right].$$

Usando a regra do produto:

- Primeira parte: $\frac{\partial}{\partial\alpha}\left(X_{i+1} - X_i e^{-\alpha\Delta} - \hat{\beta}(1-e^{-\alpha\Delta})\right) = X_i\Delta e^{-\alpha\Delta} + \hat{\beta}\Delta e^{-\alpha\Delta}$,
- Segunda parte: $\frac{\partial}{\partial\alpha}\left((X_i+\hat{\beta})\Delta e^{-\alpha\Delta}\right) = (X_i+\hat{\beta})\Delta\cdot(-\Delta e^{-\alpha\Delta})$.

A derivada total é complexa e requer aproximação numérica ou software para cálculo exato. Em prática, usa-se uma aproximação de diferença finita para $\frac{\partial^2 MQ_n}{\partial\alpha^2}$.

O procedimento que iremos utilizar para conseguir obter o valor de alpha será:

1. Escolher um α_0
2. Calcular $\hat{\beta}_k = \frac{\sum_{i=0}^{n-1}(X_{i+1} - X_i e^{-\alpha_k\Delta})}{n(1-e^{-\alpha_k\Delta})}$.
3. Avaliar $\frac{\partial MQ_n}{\partial\alpha}$ com a substituição de α_k e $\hat{\beta}_k$ na equação.

4. Aproximar $\frac{\partial^2 MQ_n}{\partial \alpha^2}$.

5. Repetimos até obtermos$|\alpha_{k+1} - \alpha_k| < 10^{-6}$.

$\hat{\alpha}$ é o valor convergente da iteração. O par estimado é $(\hat{\alpha}, \hat{\beta})$, com $\hat{\beta}$ atualizado a cada iteração.

1.3 Alínea (c)

1.3.1 Dedução das funções estimadoras de martingalas lineares

A função estimadora de martingala linear é dada por:

$$G_{1,n}(\theta) = \sum_{i=0}^{n-1} \alpha(\Delta, X_i; \theta) \left[X_{i+1} - F(X_i; \theta)\right],$$

Com,

$$\alpha(\Delta, x; \theta) = \frac{\frac{\partial F(x;\theta)}{\partial \theta}}{\phi(x; \theta)},$$

Quando,

$$F(x; \theta) = \mathbb{E}[X_\Delta | X_0 = x], \tag{3}$$

$$\phi(x; \theta) = \mathbb{V}[X_\Delta | X_0 = x] = \mathbb{E}[(X_\Delta - F(x; \theta))^2 | X_0 = x]. \tag{4}$$

onde $F(X_i; \theta) = X_i e^{-\alpha\Delta} + \beta(1 - e^{-\alpha\Delta})$.

Derivação de $\alpha(\Delta, X_i; \theta)$ Em relação a α:

$$\frac{\partial F}{\partial \alpha} = \frac{\partial}{\partial \alpha}\left[X_i e^{-\alpha\Delta} + \beta(1 - e^{-\alpha\Delta})\right] = X_i(-\Delta e^{-\alpha\Delta}) + \beta\Delta e^{-\alpha\Delta} = -\Delta(X_i - \beta)e^{-\alpha\Delta}.$$

Em relação a β:

$$\frac{\partial F}{\partial \beta} = \frac{\partial}{\partial \beta}\left[X_i e^{-\alpha\Delta} + \beta(1 - e^{-\alpha\Delta})\right] = 1 - e^{-\alpha\Delta}.$$

Assim, as funções estimadoras de martingalas lineares são:
Para α:

$$G^{\alpha}_{1,n}(\alpha, \beta, \sigma) = \sum_{i=0}^{n-1} \left[-\Delta(X_i - \beta)e^{-\alpha\Delta}\right]\left[X_{i+1} - (X_i e^{-\alpha\Delta} + \beta(1 - e^{-\alpha\Delta}))\right].$$

Para β:

$$G^{\beta}_{1,n}(\alpha, \beta, \sigma) = \sum_{i=0}^{n-1} \left[1 - e^{-\alpha\Delta}\right]\left[X_{i+1} - (X_i e^{-\alpha\Delta} + \beta(1 - e^{-\alpha\Delta}))\right].$$

Os estimadores $\hat{\alpha}$ e $\hat{\beta}$ são obtidos resolvendo:

$$G^{\alpha}_{1,n}(\hat{\alpha}, \hat{\beta}, \sigma) = 0, \quad G^{\beta}_{1,n}(\hat{\alpha}, \hat{\beta}, \sigma) = 0.$$

Para proximações iremos usar:

$$\frac{\partial F(X_i;\theta)}{\partial \theta} \approx \frac{\partial \mu(X_i;\theta)}{\partial \theta}\Delta, \quad \phi(X_i;\theta) \approx \sigma^2(X_i;\theta)\Delta,$$

onde $\mu(X_i;\theta) = \alpha(\beta - X_i)$ e $\sigma^2(X_i;\theta) = \sigma^2$.
Assim:

$$\frac{\partial \mu}{\partial \alpha} = \beta - X_i$$

$$\frac{\partial \mu}{\partial \beta} = \alpha$$

A função estimadora aproximada é:

$$\bar{G}_{1,n}(\theta) = \sum_{i=0}^{n-1} \frac{\frac{\partial \mu(X_i;\theta)}{\partial \theta}}{\sigma^2} \left[X_{i+1} - F(X_i;\theta)\right].$$

Para α:

$$\bar{G}^{\alpha}_{1,n}(\alpha,\beta,\sigma) = \sum_{i=0}^{n-1} \frac{\beta - X_i}{\sigma^2} \left[X_{i+1} - (X_i e^{-\alpha\Delta} + \beta(1 - e^{-\alpha\Delta}))\right].$$

Para β:

$$\bar{G}^{\beta}_{1,n}(\alpha,\beta,\sigma) = \sum_{i=0}^{n-1} \frac{\alpha}{\sigma^2} \left[X_{i+1} - (X_i e^{-\alpha\Delta} + \beta(1 - e^{-\alpha\Delta}))\right].$$

Os estimadores $\hat{\alpha}$ e $\hat{\beta}$ são obtidos resolvendo:

$$\bar{G}^{\alpha}_{1,n}(\hat{\alpha},\hat{\beta},\sigma) = 0, \quad \bar{G}^{\beta}_{1,n}(\hat{\alpha},\hat{\beta},\sigma) = 0,$$

também por métodos numéricos.

Ambas as equações (lineares e aproximadas) são não lineares em α e β. O método de Newton-Raphson pode ser aplicado, resolvendo o sistema iterativamente:

$$\begin{cases} G^{\alpha}_{1,n}(\alpha_k,\beta_k,\sigma) = 0, \\ G^{\beta}_{1,n}(\alpha_k,\beta_k,\sigma) = 0, \end{cases}$$

ou

$$\begin{cases} \bar{G}^{\alpha}_{1,n}(\alpha_k,\beta_k,\sigma) = 0, \\ \bar{G}^{\beta}_{1,n}(\alpha_k,\beta_k,\sigma) = 0, \end{cases}$$

atualizando α_{k+1} e β_{k+1} até à convergência (ex.: $|\alpha_{k+1} - \alpha_k| < 10^{-6}$).

1.4 Alínea (d)

1.4.1 Dedução da função de contraste baseada no esquema de Euler

O esquema de Euler discretiza a EDE como:

$$Y_{i+1} = Y_i + \mu(Y_i;\theta)\Delta + \sigma(Y_i;\theta)\Delta B_i, \quad i = 0, 1, \ldots, n-1,$$

onde:

$$
\begin{aligned}
Y_0 &= X_0, \\
\Delta B_i &= B_{t_{i+1}} - B_{t_i}, \text{ é o incremento do processo de Wiener} \\
\mu(Y_i;\theta) &= \alpha(\beta - Y_i), \text{é a deriva} \\
\sigma(Y_i;\theta) &= \sigma, \text{é a difusão (constante)}
\end{aligned}
$$

Para o processo dado, a discretização de Euler é:

$$Y_{i+1} = Y_i + \alpha(\beta - Y_i)\Delta + \sigma\Delta B_i.$$

O termo $\sigma\Delta B_i$ é um ruído gaussiano com média 0 e variância $\sigma^2\Delta$, pois $\Delta B_i \sim N(0,\Delta)$ e o fator σ escala a variância. Assim, a diferença $Y_{i+1} - Y_i$ depende linearmente de ΔB_i, e a transição condicional $Y_{i+1}|Y_i$ segue uma distribuição normal. A média condicional é:

$$E[Y_{i+1}|Y_i] = Y_i + \alpha(\beta - Y_i)\Delta,$$

e a variância condicional é:

$$\mathrm{Var}(Y_{i+1}|Y_i) = \mathrm{Var}(\sigma\Delta B_i) = \sigma^2\Delta,$$

pois a variância de ΔB_i é Δ, e σ^2 é a escala da difusão. Portanto, $Y_{i+1}|Y_i = y_i \sim N\left(y_i + \alpha(\beta - y_i)\Delta, \sigma^2\Delta\right)$.

A densidade de probabilidade de uma variável normal $Z \sim N(\mu,\sigma^2)$ é:

$$p(Z) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{(Z-\mu)^2}{2\sigma^2}\right\}.$$

Aplicando isso à transição $Y_{i+1}|Y_i$:

$Z = Y_{i+1}$, $\mu = Y_i + \alpha(\beta - Y_i)\Delta$, $\sigma^2 = \sigma^2\Delta$.

A densidade condicional é:

$$p(Y_{i+1}|Y_i;\theta) = \frac{1}{\sqrt{2\pi\sigma^2\Delta}} \exp\left\{-\frac{(Y_{i+1} - [Y_i + \alpha(\beta - Y_i)\Delta])^2}{2\sigma^2\Delta}\right\}.$$

Função verosimilhança Como o processo é markoviano, a verosimilhança conjunta para todas as observações $Y_0, Y_1, \ldots, Y_n$ é o produto das densidades condicionais:

$$L_n(\theta) = \prod_{i=0}^{n-1} p(Y_{i+1}|Y_i;\theta).$$

Substituindo a densidade:

$$L_n(\theta) = \prod_{i=0}^{n-1} \frac{1}{\sqrt{2\pi\sigma^2\Delta}} \exp\left\{-\frac{(Y_{i+1} - Y_i - \alpha(\beta - Y_i)\Delta)^2}{2\sigma^2\Delta}\right\}.$$

Essa é a função de verosimilhança baseada no esquema de Euler.

Função log- verosimilhança Tomamos o logaritmo natural de $L_n(\theta)$ para simplificar a maximização (já que o logaritmo é uma função monótona crescente):

$$\log L_n(\theta) = \log\left[\prod_{i=0}^{n-1} \frac{1}{\sqrt{2\pi\sigma^2\Delta}} \exp\left\{-\frac{(Y_{i+1} - Y_i - \alpha(\beta - Y_i)\Delta)^2}{2\sigma^2\Delta}\right\}\right].$$

Usando a propriedade do logaritmo de um produto:

$$\log L_n(\theta) = \sum_{i=0}^{n-1} \log\left[\frac{1}{\sqrt{2\pi\sigma^2\Delta}} \exp\left\{-\frac{(Y_{i+1} - Y_i - \alpha(\beta - Y_i)\Delta)^2}{2\sigma^2\Delta}\right\}\right].$$

Separamos o logaritmo:

$$\log L_n(\theta) = \sum_{i=0}^{n-1} \left[\log\left(\frac{1}{\sqrt{2\pi\sigma^2\Delta}}\right) + \log\left(\exp\left\{-\frac{(Y_{i+1} - Y_i - \alpha(\beta - Y_i)\Delta)^2}{2\sigma^2\Delta}\right\}\right)\right].$$

O primeiro termo:

$$\log\left(\frac{1}{\sqrt{2\pi\sigma^2\Delta}}\right) = \log(1) - \log(\sqrt{2\pi\sigma^2\Delta}) = -\frac{1}{2}\log(2\pi\sigma^2\Delta),$$

usando a propriedade $\log(1/x) = -\log(x)$ e $\log(\sqrt{x}) = \frac{1}{2}\log(x)$.

O segundo termo:

$$\log\left(\exp\left\{-\frac{(Y_{i+1} - Y_i - \alpha(\beta - Y_i)\Delta)^2}{2\sigma^2\Delta}\right\}\right) = -\frac{(Y_{i+1} - Y_i - \alpha(\beta - Y_i)\Delta)^2}{2\sigma^2\Delta},$$

pois $\log(\exp(x)) = x$.

Combinando:

$$\log L_n(\theta) = \sum_{i=0}^{n-1} \left[-\frac{1}{2}\log(2\pi\sigma^2\Delta) - \frac{(Y_{i+1} - Y_i - \alpha(\beta - Y_i)\Delta)^2}{2\sigma^2\Delta}\right].$$

Fatorizando os termos constantes e dependentes de θ:

$$\log L_n(\theta) = -\frac{n}{2}\log(2\pi\sigma^2\Delta) - \frac{1}{2\sigma^2\Delta}\sum_{i=0}^{n-1}(Y_{i+1} - Y_i - \alpha(\beta - Y_i)\Delta)^2,$$

onde n é o número de transições (ou seja, o número de intervalos Δ).

Função de contraste A função de contraste $C(\theta)$ é derivada a partir da log-verosimilhança, negando-a e ajustando os termos para facilitar a minimização. O objetivo é maximizar $\log L_n(\theta)$, o que equivale a minimizar $-\log L_n(\theta)$. Assim:

$$\log L_n(\theta) = -\frac{n}{2}\log(2\pi\sigma^2\Delta) - \frac{1}{2\sigma^2\Delta}\sum_{i=0}^{n-1}(Y_{i+1} - Y_i - \alpha(\beta - Y_i)\Delta)^2.$$

Ignorando o termo constante $-\frac{n}{2}\log(2\pi\sigma^2\Delta)$ (que não depende de $\theta = (\alpha, \beta, \sigma)$), a função de contraste é:

$$C(\theta) = -\log L_n(\theta) + \text{constante} = \frac{1}{2\sigma^2\Delta}\sum_{i=0}^{n-1}(Y_{i+1} - Y_i - \alpha(\beta - Y_i)\Delta)^2 + \frac{n}{2}\log(\sigma^2).$$

O termo $\frac{n}{2}\log(\sigma^2)$ é constante se σ for fixo, mas pode ser minimizado junto se σ for estimado.

Iremos então calcular o α e β, assumindo que σ é conhecido.

Derivada em relação a β

$$\frac{\partial C}{\partial \beta} = \frac{\partial}{\partial \beta}\left[\frac{1}{2\sigma^2\Delta}\sum_{i=0}^{n-1}(Y_{i+1} - Y_i - \alpha(\beta - Y_i)\Delta)^2\right].$$

O termo dentro da soma é uma função quadrática em β. A derivada parcial é:

$$\frac{\partial}{\partial \beta}\left[-\alpha(\beta - Y_i)\Delta\right] = -\alpha\Delta.$$

Usando a regra da cadeia:

$$\frac{\partial C}{\partial \beta} = \frac{1}{2\sigma^2\Delta}\cdot 2\sum_{i=0}^{n-1}(Y_{i+1} - Y_i - \alpha(\beta - Y_i)\Delta)\cdot(-\alpha\Delta).$$

Igualando a zero:

$$\sum_{i=0}^{n-1}(Y_{i+1} - Y_i - \alpha(\beta - Y_i)\Delta)\,\alpha\Delta = 0.$$

Expandindo o termo dentro do somatório:

$$Y_{i+1} - Y_i - \alpha\beta\Delta + \alpha Y_i\Delta = 0,$$

$$\sum_{i=0}^{n-1}(Y_{i+1} - Y_i + \alpha Y_i\Delta - \alpha\beta\Delta)\alpha\Delta = 0.$$

Fatorando $\alpha\Delta$:

$$\alpha^2\Delta^2\sum_{i=0}^{n-1}\beta = \alpha\Delta\sum_{i=0}^{n-1}(Y_{i+1} - Y_i + \alpha Y_i\Delta),$$

$$\hat{\beta} = \frac{\sum_{i=0}^{n-1}(Y_{i+1} - Y_i + \alpha Y_i\Delta)}{n\alpha\Delta},$$

Assumindo $\alpha \neq 0$. Note que $\hat{\beta}$ depende de α, o que indica que a minimização deve ser iterativa.

Derivada em relação a α

$$\frac{\partial C}{\partial \alpha} = \frac{\partial}{\partial \alpha}\left[\frac{1}{2\sigma^2\Delta}\sum_{i=0}^{n-1}(Y_{i+1} - Y_i - \alpha(\beta - Y_i)\Delta)^2\right].$$

A derivada parcial do termo quadrático é:

$$\frac{\partial}{\partial \alpha}\left[-\alpha(\beta - Y_i)\Delta\right] = -(\beta - Y_i)\Delta.$$

Usando a regra da cadeia:

$$\frac{\partial C}{\partial \alpha} = \frac{1}{2\sigma^2\Delta}\cdot 2\sum_{i=0}^{n-1}(Y_{i+1} - Y_i - \alpha(\beta - Y_i)\Delta)\cdot(-(\beta - Y_i)\Delta).$$

Igualando a zero:

$$\sum_{i=0}^{n-1} (Y_{i+1} - Y_i - \alpha(\beta - Y_i)\Delta)\,(\beta - Y_i)\Delta = 0.$$

Substituindo $\hat{\beta}$:

$$\sum_{i=0}^{n-1} \left(Y_{i+1} - Y_i - \alpha \left(\frac{\sum_{j=0}^{n-1}(Y_{j+1} - Y_j + \alpha Y_j \Delta)}{n\alpha\Delta} - Y_i \right) \Delta \right) (\beta - Y_i)\Delta = 0.$$

Essa equação é não linear em α e requer resolução numérica, já que $\hat{\beta}$ depende de α.

Como as equações são não lineares, usamos o método de Newton-Raphson iterativamente:

1. Escolhemos valores iniciais para α_0 e para β_0.
2. Calculamos
$$\hat{\beta}_k = \frac{\sum_{i=0}^{n-1}(Y_{i+1} - Y_i + \alpha_k Y_i \Delta)}{n\alpha_k\Delta}.$$
3. Substituímos α_k e β_k nas equações.
4. Atualizamos α_{k+1} e β_{k+1} usando as derivadas parciais e a matriz Hessiana.
5. Repetimos até existir convergência (ex.: $|\alpha_{k+1} - \alpha_k| < 10^{-6}$).

2 Pergunta 2

2.1 Alínea (a)

O código realizado para gerar tragetórias do processo $(X_t)_{t\geq 0}$ quer por meio das densiades de transição, quer através do equema de Milstein foi:

```r
library(stats)
library(ggplot2)

#### Pergunta 2 ####
# Alinea a)


# Função para gerar trajetórias do processo de Ornstein-Uhlenbeck (comum a todas as alíneas)
generate_trajectories <- function(alpha, beta, sigma, X0, TT, dt, N, n_trajectories) {
  t <- seq(0, TT, by = dt)

  # Matrizes para armazenar as trajetórias
  trajectories_transition <- matrix(0, nrow = n_trajectories, ncol = N + 1)
  trajectories_milstein <- matrix(0, nrow = n_trajectories, ncol = N + 1)

  # Condições iniciais
  trajectories_transition[, 1] <- X0
  trajectories_milstein[, 1] <- X0

  # Criação das trajetórias
  set.seed(42)
  for (i in 1:n_trajectories) {
    for (j in 1:N) {
      # Método das densidades de transição
      mean <- trajectories_transition[i, j] * exp(-alpha * dt) + beta * (1 - exp(-alpha * dt))
      var <- (sigma^2 * (1 - exp(-2 * alpha * dt))) / (2 * alpha)
      trajectories_transition[i, j + 1] <- rnorm(1, mean, sqrt(var))

      # Esquema de Milstein
      X_t <- trajectories_milstein[i, j]
      dW <- rnorm(1, 0, sqrt(dt))
      trajectories_milstein[i, j + 1] <- X_t + alpha * (beta - X_t) * dt +
        sigma * dW + 0.5 * sigma^2 * (dW^2 - dt)
    }
  }

  # Devolve as trajetórias e o tempo
  list(transition = trajectories_transition, milstein = trajectories_milstein, time = t)
}
```

Figura 1: Código relizado da alínea a)

2.2 Alínea (b)

O gráfico obtido usando as densidades de transição de uma trajetória do processo $(X_t)_{t\geq 0}$, no intervalo $[0, 100]$, com $\Delta = 0{,}01$ e considerando $\alpha = 0{,}1$, $\beta = 20$, $\sigma = 0{,}3$ e $x_0 = 20$, foi o seguinte:

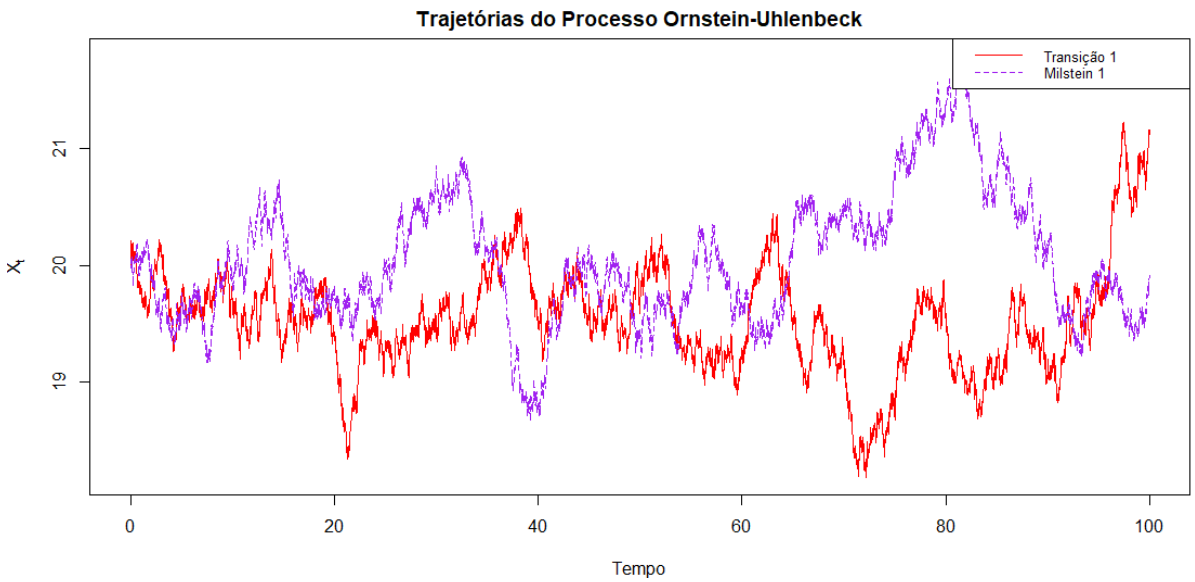

Figura 2: Gráfico gerado para a alínea (b).

O código utilizado para criar este gráfico foi:

```r
# Alínea b)

n_trajectories <- 1
params_a <- generate_trajectories(
  alpha = 0.1,
  beta = 20,
  sigma = 0.3,
  X0 = 20,
  TT = 100,
  dt = 0.01,
  N = 10000, # T /dt = 10 000
  n_trajectories = n_trajectories
)
# Cores definidas para transição e milstein
cores_transicao <- c("red", "green", "blue")
cores_milstein <- c("purple", "orange", "deeppink")

# Ajustamos as margens para o gráfico caber
par(mar = c(4, 4, 2, 1))

# Gráfico inicial com primeira trajetória
plot(
  params_a$time, params_a$transition[1, ],
  type = "l", col = cores_transicao[1],
  xlab = "Tempo", ylab = expression(X[t]),
  main = "Trajetórias do Processo Ornstein-Uhlenbeck",
  ylim = range(params_a$transition, params_a$milstein)
)
lines(params_a$time, params_a$milstein[1, ], col = cores_milstein[1], lty = 2)

# Adicionar restantes trajetórias, se existirem
if (n_trajectories_a > 1) {
  for (i in 2:n_trajectories_a) {
    cor_t <- cores_transicao[(i - 1) %% length(cores_transicao) + 1]
    cor_m <- cores_milstein[(i - 1) %% length(cores_milstein) + 1]
    lines(params_a$time, params_a$transition[i, ], col = cor_t)
    lines(params_a$time, params_a$milstein[i, ], col = cor_m, lty = 2)
  }
}
# Legendas automáticas
leg_labels <- c(
  sprintf("Transição %d", 1:n_trajectories_a),
  sprintf("Milstein %d", 1:n_trajectories_a)
)
leg_colors <- c(
  sapply(1:n_trajectories_a, function(i) cores_transicao[(i - 1) %% length(cores_transicao) + 1]),
  sapply(1:n_trajectories_a, function(i) cores_milstein[(i - 1) %% length(cores_milstein) + 1])
)
leg_lty <- c(rep(1, n_trajectories_a), rep(2, n_trajectories_a))
legend("topright", legend = leg_labels, col = leg_colors, lty = leg_lty, cex = 0.8)
```

Figura 3: Código utilizado para gerar o gráfico da alínea (b).

2.3 Alínea (c)

O código utilizado para calcular os estimadores de máxima verosimilhança foi:

```r
# Alínea c)

# Função para estimativa inicial via mínimos quadrados
initial_estimates <- function(trajectory, dt) {
  n <- length(trajectory) - 1
  alpha_init <- 0.1  # Valor inicial aproximado baseado na alínea a
  beta_init <- mean(trajectory[2:(n+1)] - trajectory[1:n] * exp(-alpha_init * dt)) / (1 - exp(-alpha_init * dt))
  residuals <- trajectory[2:(n+1)] - (trajectory[1:n] * exp(-alpha_init * dt) + beta_init * (1 - exp(-alpha_init * dt)))
  sigma_init <- sqrt(mean(residuals^2) * (2 * alpha_init) / (1 - exp(-2 * alpha_init * dt)))
  c(alpha = alpha_init, beta = beta_init, sigma = sigma_init)
}

# Função para calcular as derivadas da log-verosimilhança
compute_derivatives <- function(trajectory, alpha, beta, sigma, dt) {
  n <- length(trajectory) - 1
  Delta <- dt

  # Variância da transição
  variance_term <- (sigma^2 / (2 * alpha)) * (1 - exp(-2 * alpha * Delta))
  if (variance_term <= 0 || is.na(variance_term)) return(c(dL_da = NA, d2L_da2 = NA))

  # Resíduos
  expected <- trajectory[1:n] * exp(-alpha * Delta) + beta * (1 - exp(-alpha * Delta))
  residuals <- trajectory[2:(n+1)] - expected

  # Termo de estabilização para evitar divisões por zero
  exp_term <- exp(-2 * alpha * Delta)
  denom <- 1 - exp_term
  if (abs(denom) < 1e-10) denom <- 1e-10  # Limite inferior para evitar NA

  # Primeira derivada em relação a alpha
  dL_da <- n / (2 * alpha) - (n * Delta * exp_term) / denom +
    sum(residuals^2 / (2 * variance_term) * (Delta * exp_term) / denom)

  # Segunda derivada em relação a alpha
  d2L_da2 <- -n / (2 * alpha^2) + (2 * n * Delta^2 * exp_term) / (denom^2) +
    sum(residuals^2 / (2 * variance_term) * ((Delta^2 * exp_term) / (denom^2) -
                                              (Delta * exp_term) / denom * (1 / variance_term) * (sigma^2 / alpha) * (1 - exp_term)))

  if (is.na(dL_da) || is.na(d2L_da2) || is.infinite(dL_da) || is.infinite(d2L_da2)) {
    return(c(dL_da = NA, d2L_da2 = NA))
  }

  c(dL_da = dL_da, d2L_da2 = d2L_da2)
}
```

Figura 4: Código - parte 1: estimadores para a alínea (c).

```r
# Função para estimadores de máxima verosimilhança usando Newton-Raphson para alpha
mle_estimators <- function(trajectory, dt, initial_params, max_iter = 100, tol = 1e-6) {
  n <- length(trajectory) - 1
  alpha <- initial_params["alpha"]
  beta <- initial_params["beta"]
  sigma <- initial_params["sigma"]

  # Iteração de Newton-Raphson para alpha
  for (iter in 1:max_iter) {

    # Calcular derivadas
    derivs <- compute_derivatives(trajectory, alpha, beta, sigma, dt)
    dL_da <- derivs["dL_da"]
    d2L_da2 <- derivs["d2L_da2"]

    # Verificar se as derivadas são válidas
    if (is.na(dL_da) || is.na(d2L_da2) || is.infinite(dL_da) || is.infinite(d2L_da2)) {
      warning("Derivadas inválidas na iteração ", iter)
      break
    }

    # Atualizar alpha
    alpha_new <- alpha - dL_da / d2L_da2

    # Verificar convergência
    if (!is.na(alpha_new) && abs(alpha_new - alpha) < tol) {
      # Após convergência de alpha, otimizar beta e sigma
      expected <- trajectory[1:n] * exp(-alpha * dt) + beta * (1 - exp(-alpha * dt))
      residuals <- trajectory[2:(n+1)] - expected
      beta <- mean(residuals + trajectory[1:n] * exp(-alpha * dt)) / (1 - exp(-alpha * dt))
      variance_term <- (sigma^2 / (2 * alpha)) * (1 - exp(-2 * alpha * dt))
      sigma <- sqrt(sum(residuals^2) / (n * variance_term) * (sigma^2 / 2))
      break
    }

    alpha <- alpha_new

    # Atualizar beta e sigma
    expected <- trajectory[1:n] * exp(-alpha * dt) + beta * (1 - exp(-alpha * dt))
    residuals <- trajectory[2:(n+1)] - expected
    beta <- mean(residuals + trajectory[1:n] * exp(-alpha * dt)) / (1 - exp(-alpha * dt))
    variance_term <- (sigma^2 / (2 * alpha)) * (1 - exp(-2 * alpha * dt))
    sigma <- sqrt(sum(residuals^2) / n * (2 * alpha) / (1 - exp(-2 * alpha * dt)))
  }

  if (iter == max_iter) {
    warning("Newton-Raphson não convergiu após ", max_iter, " iterações")
  }

  list(alpha = alpha, beta = beta, sigma = sigma, iterations = iter)
}
```

Figura 5: Código - parte 2: estimadores para a alínea (c).

```r
# Usar a trajetória gerada na alínea a
trajectory <- params_a$transition[1, ]
dt <- 0.01

# Estimativa inicial
initial_params <- initial_estimates(trajectory, dt)

# Calcular estimadores de máxima verosimilhança
estimates <- mle_estimators(trajectory, dt, initial_params)

# Resultados
cat("Estimativas de Máxima Verosimilhança:\n")
cat(sprintf("alpha = %.4f (real = 0.1)\n", estimates$alpha)) # 0.1
cat(sprintf("beta = %.4f (real = 20)\n", estimates$beta)) # 19.6483
cat(sprintf("sigma = %.4f (real = 0.3)\n", estimates$sigma)) # 0.3032
cat(sprintf("Iterações: %d\n", estimates$iterations)) # 1
```

Figura 6: Código - parte 3: estimadores para a alínea (c).

```
> # Resultados
> cat("Estimativas de Máxima Verosimilhança:\n")
Estimativas de Máxima Verosimilhança:
> cat(sprintf("alpha = %.4f (real = 0.1)\n", estimates$alpha))
alpha = 0.1000 (real = 0.1)
> cat(sprintf("beta = %.4f (real = 20)\n", estimates$beta))
beta = 19.6483 (real = 20)
> cat(sprintf("sigma = %.4f (real = 0.3)\n", estimates$sigma))
sigma = 0.3032 (real = 0.3)
> cat(sprintf("Iterações: %d\n", estimates$iterations))
Iterações: 1
```

Figura 7: Resultados da estimação dos parâmetros para a alínea (c).

Os resultados obtidos foram calculados com base numa única trajetória simulada com densidades de transição.